

Prosjektrapport i DAT255 – Deep Learning Engineering

---

# Deep learning for klassifisering av lungekreft

---

30. april 2026

Kandidatnummer 429

Kandidatnummer 376

Kandidatnummer 517

**GitHub-repository:** [Chest-Cancer-Detections-Using-Deep-Learning](#)  
**Deployet modell:** [Hugging Face Space](#)

# 1 Motivasjon og mål

Kreft er en av de største dødsårsakene i verden. Ifølge SNL var det omtrent 11 430 kreftdødsfall i Norge i 2024 [6]. Lungekreft er en alvorlig kreftform der tidlig og korrekt diagnose kan være viktig for videre behandling [8]. Analyse av CT-bilder av lunger er en sentral del av diagnoseprosessen.

Motivasjonen for dette prosjektet er å undersøke om deep learning kan brukes til klassifisering av medisinske CT-bilder. Målet er å utvikle og trene en modell som kan klassifisere bilder i fire klasser: adenocarcinoma, large cell carcinoma, squamous cell carcinoma og normal.

## 1.1 Problemstilling

Hvordan kan vi ved hjelp av deep learning utvikle en modell som kan klassifisere medisinske bilder av lunger i ulike kategorier?

## 1.2 Løsningens bruksområde

Løsningen er utviklet som en eksperimentell prototype for å undersøke hvordan deep learning kan brukes til klassifisering av CT-bilder av lunger. Modellen er ikke ment for klinisk bruk, og skal ikke brukes til diagnostisering i medisinsk behandling.

Gjennom en enkel Gradio-applikasjon på Hugging Face kan brukere laste opp et bilde og se modellens prediksjon. Dette brukes kun som en demonstrasjon for hvordan en deep learning-modell kan brukes i et brukergrensesnitt. Resultatene må tolkes kritisk, særlig fordi modellen er trent på et begrenset datasett og har begrenset nøyaktighet.

## 1.3 Hvorfor deep learning?

Deep learning er godt egnet til å analysere bilder. Neural networks kan lære komplekse mønstre fra data som den kan bruke til å klassifisere usette bilder, noe som ellers ville vært vanskelig i tradisjonell koding hvor klassene kan være vanskelig å beskrive med egendefinerte regler.

Deep learning-modeller, som Convolutional Neural Networks og transfer learning, er spesielt godt egnet for en slik problemstilling. Modellene lærer mønstre i data, og bruker dette til å kunne generalisere nye usette bilder.

## 1.4 Eksisterende løsninger

Det finnes eksisterende løsninger på Kaggle som bruker samme eller relativt like datasett ved bruk av deep learning. Bruken av deep learning innenfor design og forskning er ikke et uskjent tema. Det finnes løsninger som blir brukt i produksjon innen forskningsarbeid som oppnår høy nøyaktighet, men krever store mengder med data og prosesseringskraft. Dette prosjektet skiller seg ut med å:

- Jobbe med et relativt lite datasett
- Utforske forskjellige modeller (FFNN, CNN og transfer learning)
- Tolkning av oppdagelser underveis i utviklingsprosessen

## 1.5 Evaluering av resultat

For å evaluere modellene gjennom utviklingen, blir det tatt i bruk forskjellige metoder:

- Accuracy: hvor stor andel av prediksjonene som var riktige
- Precision: hvor stor andel av modellens prediksjoner for en klasse som faktisk var riktige
- Recall: hvor stor andel av bildene i en klasse modellen klarte å finne
- F1-score: et kombinert mål basert på precision og recall
- Confusion matrix: viser hvilke klasser modellen predikerte riktig, og hvilke klasser den forvekslet

Det vil også bli tatt i bruk grafer av modellens accuracy og loss gjennom trenings- og valideringsfasene.

En modell anses å være vellykket hvis den:

- Oppnår høy accuracy
- Fanger mønster i treningsdata og generaliserer godt til testdata
- Viser forbedring opp mot baseline-modellen

## 2 Data

Datasettet som ble brukt i prosjektet består av CT-bilder kategorisert i fire klasser: adenocarcinoma, large cell carcinoma, squamous cell carcinoma og normal. Dette gjør datasettet relevant for problemstillingen, siden målet er å undersøke hvordan deep learning kan brukes til bildeklassifisering innen lungkreft. Samtidig må resultatene tolkes med forsiktighet, ettersom datasettet er relativt lite og ikke nødvendigvis representerer klinisk variasjon i reelle diagnoseprosesser.

### 2.1 Valg av datasett

Datasettet var valgt fordi det var relevant for prosjektets problemstilling og allerede var strukturert i mapper etter klasse. Dette var med på å gjøre trening og evalueringen av modeller mer effektivt. Prosjektet drøfter et gjentakende problem i deep learning med medisinske bilder.

En annen grunn til at datasettet ble valgt, var at det var lett tilgjengelig gjennom Kaggle [4]. Dette gjorde det mulig å komme raskt i gang med utvikling uten behov for egen innsamling eller merking av bilder.

Datasettet inneholder totalt 1000 bilder fordelt på trenings-, validerings- og testsett. Treningssettet består av 613 bilder, valideringssettet av 72 bilder og testsettet av 315 bilder. Dette blir omtrent 61,3 % treningsdata, 7,2 % valideringsdata og 31,5 % testdata.

Fordelingen mellom klassene var ikke helt balansert. Adenocarcinoma var den største klassen med totalt 338 bilder, mens large cell carcinoma var den minste klassen med totalt 187 bilder.

Tabell 1: Fordeling av bilder i datasettet.

| Klasse                  | Treningssett | Valideringssett | Testsett | Totalt |
|-------------------------|--------------|-----------------|----------|--------|
| Adenocarcinoma          | 195          | 23              | 120      | 338    |
| Large cell carcinoma    | 115          | 21              | 51       | 187    |
| Normal                  | 148          | 13              | 54       | 215    |
| Squamous cell carcinoma | 155          | 15              | 90       | 260    |
| Totalt                  | 613          | 72              | 315      | 1000   |

Som vist i Tabell 1, var datasettet ikke helt balansert mellom klassene. Dette kan påvirke treningen ved at modellen lærer mer fra klassene med flest eksempler, og kan gjøre det vanskeligere å oppnå god ytelse på de mindre klassene.

### 2.2 Fordeler og ulemper

En av fordelene med å bruke datasettet, er at det medisinske feltet er veldig relevant når det kommer til bruk av kunstig intelligens. Dette gir prosjektet godt utbytte av erfaring og en metode for å teste ulike modelltyper og sammenligne ytelsen.

Samtidig har datasettet flere ulemper:

- Det var relativt lite, noe som øker risiko for overfitting
- Det var ubalanse mellom klassene
- Bildene hadde variasjon i kvalitet og struktur.

Ulempene gjorde prosjektet mer utfordrende i praksis.

## 2.3 Alternative datasett

Det finnes større datasett for medisinsk bildeanalyse. Et eksempel er forskningsdatasett brukt i academia, men de datasettene har som regel restriksjoner på grunn av medisinske og private opplysninger.

Prosjektets datasett bruker derfor et åpent datasett fra Kaggle. Dette var praktisk for et studentprosjekt, men kommer med begrensninger knyttet til datamengde, kvalitet og generaliserings-evne.

## 2.4 Ferdigtrente modeller og treningsdata

I prosjektet ble MobileNetV2 brukt som grunnlag for transfer learning. MobileNetV2 er en forhåndstrent modell som er trent på ImageNet, et stort bildedatasett med millioner av bilder fordelt på mange ulike klasser.

ImageNet har ikke medisinske bilder, men har lært generelle visuelle trekk som kan være nyttige i medisinske oppgaver. Ved å bruke en forhåndstrent modell kan prosjektet utnytte disse representasjonene i stedet for å trene en modell fra bunnen av. Dette er spesielt nyttig når datasettet er relativt lite.

## 2.5 Datapreprosessering

Før modellene kunne trenes, måtte dataene preprosesserer slik at de fikk et konsistent format. Bildene ble skalert til 128x128 piksler, og datasettet var allerede delt inn i trenings-, validerings- og testsett.

For FFNN- og CNN-modellene ble pikselverdiene normalisert til intervallet 0–1. For MobileNetV2 ble Keras sin egen preprocessing-funksjon brukt, siden denne modellen forventer en annen skalering av inputdataene.

Dette gjorde at modellene fikk et fast inputformat, samtidig som preprocessing var tilpasset de ulike modelltypene.

## 2.6 Data augmentation

I prosjektet så ble det brukt data-augmentation for å øke variasjonen i treningsdataene og redusere risikoen for overfitting. Teknikken som ga beste resultat var tilfeldig zoom, som introduserte variasjon i bildene ved å forstørre eller forminske deler av bildet innenfor et avgrenset område (F. Chollet, 2025).

Flere andre teknikker, som rotasjon og horisontal speiling, ble også testet, men ga svakere resultater. Dette kan tyde på at slike transformasjoner endret viktige mønstre i bildene, og dermed gjorde det vanskeligere for modellen å lære relevante forskjeller mellom klassene.

Data-augmentering ble derfor brukt forsiktig. Dette er særlig viktig når det jobbes med medisinsk bildeanalyse, hvor feilinformasjon kan påvirke informasjon som er relevant for klassifisering.

## 3 Implementering av modell

### 3.1 Oversikt over modeller

Gjennom prosjektet ble flere ulike modeller implementert og evaluert for å undersøke hvor godt de kunne klassifisere CT-bildene i de fire klassene. Modellene ble gradvis gjort mer avanserte, slik at resultatene fra enklere modeller kunne brukes som sammenligningsgrunnlag for mer komplekse modeller.

Følgende modeller ble testet:

- Baseline-modell.
- Enkel Feed Forward Neural Network (FFNN)
- Enkel Convolutional Neural Network (CNN)
- Forbedret CNN
- CNN med data augmentation og regularisering
- Transfer learning-modell basert på MobileNetV2
  - med frozen base
  - med fine-tuning

Delen av prosjektet som omhandler transfer learning og utvikling av modellarkitektur ble delvis utviklet med støtte fra ChatGPT. Dette ble brukt som hjelp til å utforske mulige modellstrukturer og implementasjonsvalg innenfor prosjektets tidsramme. Modellene ble likevel testet, evaluert og sammenlignet av prosjektgruppen.

De ulike modellene viser prosjektets iterative utvikling, der resultatene fra tidligere modeller ble brukt til å gjøre justeringer i senere modeller. Modellene ble sammenlignet med blant annet accuracy, precision, recall, F1-score og confusion matrix.

### 3.2 Begrunnelse for valget av modell

En baseline-modell ble først laget for å gi et grunnlag som kunne sammenlignes med de mer avanserte modellene. Baseline-modellen predikerte alle bilder som adenocarcinoma, siden dette var den største klassen i treningssettet og ville derfor gi høyest accuracy.

Etter baseline-modellen ble det laget en enkel Feed Forward Neural-Network (FFNN). Denne modellen tar ikke hensyn til strukturen i bilder. Bildene blir representert som tall og flatet ut til en lang sekvens av tall og forventes derfor å prestere dårlig.

Deretter ble Convolutional Neural-Network (CNN) brukt, som i motsetning til FFNN er spesielt godt egnet for bildeanalyse. Ved bruk av konvolusjonslag kan modellen lage gode representasjoner av bilder og derfor lære komplekse mønstre i data.

Til slutt ble transfer learning brukt ved hjelp av MobileNetV2, en forhåndstreint CNN-modell som allerede har lært generelle visuelle trekk fra ImageNet. Dette er spesielt nyttig i dette prosjektet siden ferdigtreinte modeller ikke er like avhengig av store mengder data som andre utrente modeller.

### 3.3 Modellstruktur

Alle modellene ble sammenlignet på slutten av prosjektet hvor den beste modellen ble valgt. Transfer Learning var den modellen med best resultat og ble derfor valgt. Modellen tar som input, bilder med størrelse 128x128 piksler og tre farger. Før bildene ble sendt inn i modellen ble det lagt til en enkel data augmentation som inneholdt tilfeldig zoom.

Det ble brukt enkel data augmentation i form av tilfeldig zoom. Andre teknikker, som rotasjon og horisontal speiling, ble også testet, men ga svakere resultater. Dette kan tyde på at slike transformasjoner endrer viktige mønstre i bildene. Derfor ble data augmentation brukt forsiktig.

Kjernen i modellen består av MobileNetV2, en forhåndstrent konvolusjonsmodell trent på ImageNet-datasettet. I denne versjonen er de forhåndsdefinerte vektene frosset. Det betyr at modellen ikke oppdaterer de interne vektene, men kun bruker de ferdigtrente representasjonene til å finne mønstre i bildene.

Etter MobileNetV2 ble det lagt til et Global Average Pooling-lag. Dette reduserer dimensjonaliteten i feature maps fra MobileNetV2 og gjør dem til en mer kompakt representasjon. Deretter følger det et Dense-lag med ReLU-aktiveringsfunksjon som lærer sammenhenger.

For å redusere overfitting ble det brukt Dropout etter Dense-laget. Dropout deaktiverer tilfeldig utvalgte nevroner under trening, slik at modellen blir mindre avhengig av enkeltforbindelser. Til slutt består modellen av et output-lag med softmax-aktiveringsfunksjon som regner ut sannsynligheten over de fire klassene: adenocarcinoma, large cell, squamous og normal.

### 3.4 Hyperparametre

Flere hyperparametre påvirker hvordan modellene trente og hvor godt de generaliserte til validerings- og testdata. I prosjektet ble hyperparametrene hovedsakelig justert manuelt basert på observasjoner fra treningskurver, validation loss, validation accuracy og confusion matrix. Hyperparameterne ble ikke optimalisert gjennom systematisk søk som grid search eller random search.

De viktigste hyperparametrene var:

- **Learning rate:** styrer hvor store vektoppdateringer modellen gjør under trening. For høy learning rate kan føre til ustabil trening, mens for lav learning rate kan gjøre treningen treg eller føre til at modellen ikke lærer godt nok.
- **Batch size:** bestemmer hvor mange bilder modellen ser før vektene oppdateres. I prosjektet ble det brukt en batch size på 32.
- **Antall epoker:** bestemmer hvor mange ganger modellen trenes gjennom treningsdatasettet. Antall epoker varierte mellom modellene, og early stopping ble brukt for å redusere risikoen for overfitting.
- **Dropout-rate:** ble brukt i flere modeller for å redusere overfitting ved å deaktivere tilfeldige nevroner under trening.
- **Antall lag og filtre:** i CNN-modellen ble modellarkitekturen justert ved å endre antall konvolusjonslag, filtre og dense-lag.
- **Data augmentation-parametre:** ulike former for augmentering ble testet, blant annet zoom, rotasjon og horisontal speiling. Tilfeldig zoom ga best resultat i den endelige modellen.

### 3.5 Treningsprosess

Modellene ble trent som en flervalgsklassifiseringsoppgave med fire klasser: adenocarcinoma, large cell carcinoma, normal og squamous cell carcinoma. Datasettene ble lastet inn med `image_dataset_from_directory`, der bildene ble skalert til 128x128 piksler og labelene ble representert som heltallsverdier. Batch size ble satt til 32.

For FFNN- og CNN-modellene ble pikselverdiene skalert til intervallet 0–1 ved hjelp av `Rescaling(1.0 / 255)`. For transfer learning-modellen med MobileNetV2 ble Keras-funksjonen `mobilenet_v2.preprocess_input` brukt, siden MobileNetV2 forventer en egen form for preprocessing.

Alle modellene ble kompilert med `sparse_categorical_crossentropy` som loss-funksjon. Dette passer for flervalgsklassifisering der klassene er representert som heltallsverdier.

## 3.6 Kode og repo

Koden for prosjektet er tilgjengelig i et repository på GitHub<sup>1</sup>.

Repositoriet inneholder:

- Datapreprossessering
- Utforskning og sammenligning av modeller
- Trening og validering
- Visualisering av resultatene, gjennom blant annet grafer og figurer
- App-kode for Hugging Face-deployment

Modellen som ble utviklet er tilgjengelig på Hugging Face<sup>2</sup>.

Merk at koden laget for å generere grensesnittet er utviklet ved hjelp av ChatGPT.

## 4 Evaluering

### 4.1 Resultater

Modellene ble evaluert ved hjelp av accuracy, precision, recall, F1-score og confusion matrix. Accuracy viser hvor stor andel av bildene modellen klassifiserte riktig, men siden datasettet var ubalansert, var det viktig å også bruke metrikker som precision, recall og F1-score. Dette er spesielt viktig i en medisinsk oppgave, der feilklassifisering kan ha store konsekvenser.

Baseline-modellen predikerte alle bilder som adenocarcinoma, siden dette var den største klassen i treningssettet. På valideringssettet ga dette en accuracy på rundt 32 %. Denne modellen ga et enkelt sammenligningsgrunnlag som de mer avanserte modellene burde prestere bedre enn.

Tabell 2: Sammenligning av modellene på valideringssettet.

| Modell                          | Accuracy | Precision macro | Recall macro | F1 macro | F1 weighted |
|---------------------------------|----------|-----------------|--------------|----------|-------------|
| Transfer learning (frozen base) | 0.653    | 0.728           | 0.668        | 0.669    | 0.657       |
| Transfer learning (fine-tuned)  | 0.597    | 0.721           | 0.627        | 0.615    | 0.597       |
| FFNN                            | 0.556    | 0.568           | 0.556        | 0.548    | 0.549       |
| Larger CNN                      | 0.528    | 0.620           | 0.544        | 0.533    | 0.510       |
| Improved CNN                    | 0.500    | 0.453           | 0.517        | 0.452    | 0.408       |
| CNN from scratch                | 0.472    | 0.408           | 0.496        | 0.434    | 0.391       |
| FFNN + augmentation             | 0.417    | 0.340           | 0.385        | 0.307    | 0.295       |

Den beste modellen, som sett i Tabell 2 var en transfer-learning modell basert på MobileNetV2. Modellen oppnådde omtrent 65 % accuracy på valideringssettet og omtrent 68 % accuracy på testsettet. Macro F1-score lå rundt 0.67-0.69, noe som viser at modellen presterte bedre enn baseline, men fortsatt hadde tydelige begrensninger.


Resultatene viser at MobileNetV2 ga en tydelig forbedring sammenlignet med enklere modeller som baseline, FFNN og enkle CNN-modeller. Samtidig er ytelsen for lav til at modellen kan brukes i en reell medisinsk sammenheng. Modellen bør derfor tolkes som en eksperimentell prototype og ikke som et verktøy.

<sup>1</sup>GitHub-repository: <https://github.com/chritof/Chest-Cancer-Detections-Using-Deep-Learning>

<sup>2</sup>Modell via Hugging Face: [https://chrto13-chest-canser.hf.space/?\\_\\_theme=system&deep\\_link=deKbk-Rd6ws](https://chrto13-chest-canser.hf.space/?__theme=system&deep_link=deKbk-Rd6ws)

## 4.2 Evaluering av modellens ytelse

Confusion matrix ble brukt for å undersøke hvilke klasser modellen predikerte riktig, og hvilke klasser den forvekslet. Som vist i Figur 1, klarte modellen i større grad å skille normale bilder fra bilder med kreft, men hadde større problemer med å skille mellom de ulike krefttypene: adenocarcinoma, large cell carcinoma og squamous cell carcinoma.




Figur 1: Confusion matrix for den endelige MobileNetV2-modellen.

Dette er en viktig begrensning, fordi feilklassifisering mellom krefttyper kan være problematisk i en medisinsk kontekst. Lav recall for enkelte klasser betyr at modellen ikke oppdager relevante tilfeller i disse klassene. I medisinsk bildeanalyse er dette spesielt problematisk, siden falske negative prediksjoner kan føre til at sykdom ikke blir fanget opp av modellen.

For å få bedre innsikt i modellens feil ble noen feilklassifiserte bilder fra testsettet undersøkt manuelt. Dette ble brukt som en kvalitativ feilanalyse, der målet var å se om feilene samsvarte med mønstrene fra confusion matrix.





Figur 2: Eksempler på feilklassifiserte bilder fra testsettet.

Figur 2 viser fire eksempler på adenocarcinoma-bilder fra testsettet som modellen klassifiserte feil. Flere av eksemplene viser bilder som modellen predikerte som enten squamous cell carcinoma eller large cell carcinoma. Dette samsvarer med confusion matrix, hvor modellen hadde større problemer med å skille mellom de ulike krefttypene enn å skille normale bilder fra unormale bilder.


Noen av feilprediksjonene hadde relativt høy confidence. Dette viser at modellen i enkelte tilfeller kan gi høy sannsynlighet til en feil klasse. I en medisinsk kontekst er dette en viktig begrensning, fordi prediksjoner med høy confidence fortsatt kan være feil og derfor må vurderes kritisk.

En mulig forklaring på at transfer learning-modellen hadde problemer med å skille mellom enkelte krefttyper, er at MobileNetV2 er trent på ImageNet, som består av generelle bilder og ikke medisinske CT-bilder. Modellen kan derfor være god til å fange generelle visuelle trekk, som kanter, former og teksturer, men er ikke nødvendigvis optimalisert for små forskjeller i medisinske bilder.


Analysen av feilklassifiserte bilder støtter derfor vurderingen om at modellen fungerer som en eksperimentell prototype, men ikke er egnet for klinisk bruk. En mer detaljert analyse, for eksempel med Grad-CAM, kunne gi bedre innsikt i hvilke deler av bildene modellen faktisk vektlegger når den gjør prediksjoner.

### 4.3 Overfitting og generalisering

Trenings- og valideringskurvene ble brukt for å undersøke om modellen generaliserte godt til nye data, eller om den viste tegn til overfitting. Overfitting oppstår når modellen lærer mønstre som er for spesifikke for treningsdataene, slik at den presterer dårligere på validerings- eller testdata.



Figur 3: Accuracy for trenings- og valideringssett gjennom epokene.



Figur 4: Loss for trenings- og valideringssett gjennom epokene.

Figur 3 og Figur 4 viser at modellen lærer fra treningsdataene, men at valideringsresultatene blir ustabile etter hvert i treningen. Valideringsloss begynner også å øke etter en del epoker, samtidig som treningsloss fortsetter å gå ned. Dette tyder på at modellen etter hvert begynner å tilpasse seg treningsdataene for mye.

Dette kan henge sammen med at datasettet er relativt lite og ubalansert. Når modellen har få eksempler å lære fra, øker risikoen for at den lærer detaljer i treningsdataene i stedet for generelle mønstre som også fungerer på nye bilder. Resultatene bør derfor tolkes med forsiktighet, selv om modellen oppnår bedre ytelse enn baseline-modellen.

For å redusere overfitting ble det testet teknikker som dropout, data augmentation og early stopping. Likevel viser resultatene at modellen fortsatt har begrenset generaliseringsevne, og at et større og mer balansert datasett sannsynligvis ville vært nødvendig for å gjøre modellen mer robust.

## 4.4 Vurdering av metrikker

For å evaluere modellene ble det brukt accuracy, precision, recall, F1-score og confusion matrix. Accuracy ga en enkel oversikt over hvor stor andel av bildene modellen klassifiserte riktig, men var ikke nok alene. Dette skyldes blant annet at datasettet var ubalansert, og at en modell kan oppnå relativt god accuracy selv om den presterer svakt på enkelte klasser.

Precision og recall ga mer detaljert innsikt i hvilke typer feil modellen gjorde. Precision viste hvor ofte prediksjonene innen en klasse faktisk var riktige, mens recall viste hvor stor andel av bildene i en klasse modellen klarte å finne. Dette var spesielt viktig i dette prosjektet, fordi lav recall for en kreftklasse betyr at modellen ikke oppdager alle relevante tilfeller i den klassen.

F1-score var nyttig fordi den kombinerer precision og recall. Macro F1-score var særlig relevant, siden den vurderer ytelsen på tvers av klassene uten at de største klassene får for mye påvirkning på resultatet. Weighted F1-score tar hensyn til hvor mange eksempler det finnes i hver klasse, slik at større klasser får mer påvirkning. I prosjektet var macro F1-score brukt fordi det var viktig å vurdere ytelsen på alle krefttypene, ikke bare de største klassene.

Confusion matrix var også viktig i evalueringen, fordi den viste konkret hvilke klasser modellen forvekslet med hverandre. Dette gjorde det lett å se at modellen hadde større problemer med å skille mellom de ulike krefttypene enn å skille normale bilder fra unormale bilder.

Disse metrikkene var godt egnet til å evaluere modellene i prosjektet. Samtidig viser resultatene at modellen fortsatt har begrensninger, og at metrikker som recall og F1-score er viktig i medisinsk klassifisering.

## 5 Deployment

### 5.1 Hvordan modellen er deployet

For å demonstrere bruken av modellen, ble den beste modellen, som bestod av transfer learning med frossen MobileNetV2, lagt ut på en nettside ved hjelp av Hugging Face Spaces.

Brukere kan gå inn på tjenesten og laste opp et bilde som vil bli prosessert på samme måte som under trening. Bildet sendes gjennom alle lagene i modellen, hvor modellen returnerer sannsynligheten for at inputbildet hører til de forskjellige klassene. Resultatet vises i grensesnittet som sannsynligheter for hver av de fire klassene.

### 5.2 Rammeverk

Prosjektet brukte TensorFlow/ Keras for modellutvikling og Gradio for å bygge brukergrensesnittet.

TensorFlow gav en god og strukturert måte å jobbe på gjennom hele prosjektet, fra modelltrening til lagring og lasting av modeller.

Gradio ble valgt som frontend-løsning fordi det gir en enkel og grei måte å bygge nett-baserte applikasjoner på for maskinlæringsmodeller. Integrasjonen med Hugging Face gjør det også lett å publisere et grensesnitt på applikasjonen.

### 5.3 Monitorering og vedlikehold

For at modellen faktisk skal være nyttig over tid, krever det monitorering og vedlikehold.

Dersom løsningen skulle videreutvikles, kunne det vært nyttig å logge modellens prediksjoner og ytelse over tid. Siden medisinske bilder kan inneholde sensitiv informasjon, måtte dette i så fall gjøres med tydelige personvernregler, anonymisering og uten unødvendig lagring av råbilder.

Endring av måten vi tar CT-bilder på kan være en viktig faktor, og må overvåkes. Modellen er trent på én type CT-bilder, men teknologi endres og måten vi tar CT-bilder på i dag, er kanskje endret om noen år. Dette gjør at jevnlig evaluering og eventuelt ny trening er nødvendig.

## 5.4 Videre forbedringer

Ut ifra analyse og tidligere diskusjon i rapporten, kan vi konkludere med at modellen må videreutvikles for å bli tatt i bruk. En av de tingene som kan forbedres er at modellen får et større og mer balansert datasett å jobbe med, slik at modellen kan være mer nøyaktig og hindre overfitting.

En annen mulig forbedring kunne vært å legge til mer avanserte teknikker for hyperparameter-optimalisering. I dette prosjektet ble hyperparameterene valgt manuelt. Ved å bruke verktøy som grid search eller random search, kunne man oppnådd en mer effektiv og robust modell på en mer strukturert måte.

Det kan også diskuteres om alternativ modellarkitektur kan gi bedre svar, men å undersøke forskjellige modellarkitekturer er noe som er tidskrevende og sluker tid i et prosjekt som har en tidsfrist.

Brukeropplevelsen kan forbedres med å legge til et mer avansert brukergrensesnitt ved å for eksempel legge til forklaring av modellens predikasjoner.

# 6 Konklusjon

## 6.1 Vurdering av prosjektet

Målet med prosjektet var å undersøke om deep learning kan brukes til å klassifisere CT-bilder av lunger for å predikere forskjellige klasser av kreft. Flere modeller og forbedringer ble gjort gjennom prosjektet, fra enkel baseline-modell og FFNN til CNN-modeller og transfer learning med MobileNetV2.

Resultatene viste at transfer learning ga best ytelse i dette prosjektet. Modellen med frossen MobileNetV2-base oppnådde omtrent 65 % accuracy og en macro F1-score på omtrent 0.67 på valideringssettet. Dette var en forbedring sammenlignet med de enklere modellene, men resultatene viser samtidig at modellen har begrensninger. Modellen hadde utfordringer med å skille mellom ulike krefttyper, selv om den i større grad klarte å skille kreft fra ikke-kreft.

Prosjektet viste også at data augmentation ikke nødvendigvis forbedrer resultatene. FFNN-modellen med data augmentation gjorde det desidert verst. Sannsynligvis fordi transformasjoner kan endre viktige strukturer i bildene og gjøre oppgaven vanskeligere for modellen. I tillegg ble det observert at resultatene var følsomme for valg av seed, noe som tyder på at datasettet var relativt lite og ubalansert.

## 6.2 Hva kunne vært annerledes?

I ettertid er det flere ting som kunne vært forbedret. Det viktigste ville vært å bruke et større og mer balansert datasett. Dette kunne redusert risikoen for overfitting og gitt modellen bedre grunnlag for å lære mønstre.

Klasseubalanse kunne også vært håndtert bedre, for eksempel ved bruk av class weights eller andre teknikker som gir mindre klasser større betydning under trening. I tillegg kunne hyperparameter-optimalisering vært bedre, gjerne gjort ved hjelp av grid search eller random search.

En alternativ tilnærming kunne vært å gjøre oppgaven om til binær klassifisering, der modellen kun skiller mellom normal og unormal/kreft. Dette ville sannsynligvis gjort klassifiseringsproblemet enklere og gitt høyere nøyaktighet. Samtidig ville modellen mistet evnen til å skille mellom ulike krefttyper, noe som reduserer nytten.

### 6.3 Helhetlig vurdering

Prosjektet viser tydelig hvordan valg av modeller og metoder påvirker resultatet i deep learning. Gjennom analyse og sammenligning av modeller har det vært mulig å finne både styrker og svakheter som brukes for å videreutvikle modeller, og komme til en endelig modell. Modellen fungerer som en prototype, men er ikke egnet for praktisk bruk uten betydelig videreutvikling.

Denne modellen ga et realistisk resultat, og prosjektet ga nyttig innsikt i hvordan ulike modeller presterer på et lite medisinsk bildedatasett, og viste viktigheten av kritisk vurdering av resultat, metrikker og modellens begrensninger.

## Kilder

- [1] François Chollet. *Deep Learning with Python*. 3. utg. Manning, 2025.
- [2] DAT255 – Deep Learning Engineering. *Forelesningsnotater og notebooks*. Kursmateriell. Høgskulen på Vestlandet, 2026.
- [3] Hugging Face. *Spaces*. <https://huggingface.co/spaces>. Hentet 23. april 2026.
- [4] Kaggle. *Chest CT-Scan Images Dataset*. <https://www.kaggle.com/datasets/mohamedhanyyy/chest-ctscan-images>. Hentet 24. februar 2026.
- [5] OpenAI. *ChatGPT*. Brukt som støtte til kodeforslag, språk, strukturering av deler av implementasjonen og formattering av rapport. 2026.
- [6] Borghild Roald mfl. *Kreft*. <https://sml.snl.no/kreft>. Store medisinske leksikon. Hentet 27. april 2026.
- [7] TensorFlow. *TensorFlow API documentation*. [https://www.tensorflow.org/api\\_docs/python/tf/all\\_symbols](https://www.tensorflow.org/api_docs/python/tf/all_symbols). Hentet 20. april 2026.
- [8] World Health Organization. *Cancer*. <https://www.who.int/news-room/fact-sheets/detail/cancer>. Hentet 27. april 2026.