

Prosjektrapport i DAT255 – Deep Learning Engineering

Deep learning for klassifisering av lungekreft

Dato

Christoffer Toftevåg (kand.nr. 123456)

David Bao Bui (kand.nr. 234567)

Jeg bekrefter at arbeidet er selvstendig utarbeidet, og at referanser/kildehenvisninger til alle kilder som er brukt i arbeidet er oppgitt, jf. Forskrift om studium og eksamen ved Høgskulen på Vestlandet, § 10.

Navn gruppedlem 3 (kand.nr. 345678)

Denne malen inneholder beskrivelse av en del punkter som kan være nyttige å diskutere i hver seksjon. Disse er foreslåtte ting å dekke; dere kan hoppe over punkter som ikke er relevante til gjennomføringen og evalueringen av deres prosjekt. Husk at målet med rapporten er å vise at dere behersker de viktige elementene i dyp læring. Hoveddelen av teksten bør være fokusert på modellering og evaluering. Slett alle instruksjonene i malen (skrevet i kursiv) før dere leverer.

Motivasjon og mål

Kreft er en av de største grunnene til død i verden. Ifølge SNL var det omtrent 11 430 kreftdødsfall i Norge i 2024 (Erik Bolstad, Store norske leksikon). Det finnes forskjellige krefttyper, hvor i 2022 var den mest vanlige typen lungekreft, ifølge World Health Organization (skrevet av...) , noe som viser viktigheten av tidlig og korrekt diagnose. Analyse av CT-skanning av lunger er en sentral del av diagnoseprosessen.

Motivasjonen for dette prosjektet er å undersøke om deep learning kan hjelpe til i denne krevende og viktige diagnoseprosessen, basert på medisinske bilder. Målet er å utvikle og trene opp en modell som kan predikere forskjellige typer lungekreft som adenocarcinoma, large cell carcinoma, squamous cell carcinoma og friske pasienter som kan fungere som et hjelpeverktøy under diagnoseprosessen.

Problemstilling

Hvordan kan vi ved hjelp av deep learning utvikle en modell som kan klassifisere medisinske bilder av lunger i ulike kategorier.

Løsningens bruksområde

modellen som blir utviklet kan brukes som et hjelpeverktøy av helsepersonell under diagnoseprosessen av lungekreft. Modellen alene skal ikke konkludere om pasienten er frisk eller syk, men være et verktøy for å hjelpe helsepersonell med en konklusjon. Modellen skal kunne brukes gjennom Huggingface, hvor brukere kan laste opp bilder og få predikasjoner. Dette demonstrerer nytten til modellen og viser hvordan modellen kan bli tatt ut i en realistisk setting. Igjen, er det viktig å understreke at modellen ikke er ment til å erstatte medisinsk ekspertise, men heller fremstå som et nyttig verktøy.

Hvorfor deep learning?

Deep learning er godt egnet til å analysere bilder. Neural networks kan lære komplekse mønstre fra data som den kan bruke til å klassifisere usette bilder, noe som ellers ville vært vanskelig i tradisjonell koding hvor klassene kan være vanskelig å beskrive med egendefinerte regler.

Deep learning sine modeller som Convolutional Neural Networks og transfer learning, er spesielt godt egnet for en slik problemstilling. Modellene lærer fanger mønstre i data, og bruker dette til å kunne generalisere nye usette bilder.

Eksisterende løsninger

Det finnes eksisterende løsninger på Kaggle som bruker samme eller relativt like datasett ved bruk av deep learning. Bruken av deep learning innenfor design og forskning er ikke et uskjent tema. Det finnes løsninger som blir brukt i produksjon innen forskningsarbeid som oppnår høy nøyaktighet, men krever store mengder med data og prosesserings kraft.

Dette prosjektet skiller seg ut med å:

- jobbe med et relativt lite datasett
- utforske forskjellige modeller (FFNN, CNN og transfer learning)

- tolkning av oppdagelser underveis i utviklingsprosessen

Evaluering av resultat

For å evaluere modellene gjennom utviklingen, blir det tatt i bruk forskjellige metoder:

- Accuracy: hvor stor andel av predikasjonene var riktige
- Precision: hvor mange riktige predikasjoner faktisk var riktig
- Recall: hvor godt modellen klarer å finne riktige tilfeller
- F1-score: balanse mellom recall og precision
- Confusion matrix: gir en god oppsummering av modellens predikasjoner opp mot de rette klassene

Det vil også bli tatt i bruk grafer av modellens accuracy og loss gjennom trenings- og valideringsfasene.

En modell anses å være vellykket hvis den:

- oppnår en høy accuracy
- fanger mønster i treningsdata og generaliserer godt til testdata
- viser forbedring opp mot basemodellen

Data

Beskriv dataene dere bruker, og hvorfor dere valgte dem.

- *Diskutér fordeler og ulemper ved datasettet, og hvorfor det passer for dyp læring.*
- *Finnes det alternative datasett?*

- *Dersom dere skal sammenligne deres modell(er) til ferdigtrente modeller, beskriv hvilke data disse er trent på.*
- *Beskriv eventuell omformatering som var nødvendig før dataene kunne brukes.*
- *Beskrive augmenteringsteknikker dere brukte.*

Implementering av modell

Oversikt over modeller

Gjennom prosjektet ble det tatt i bruk ulike modeller for å teste og analysere modellenes ytelse til å riktig klassifisere de ulike bildene. Disse modellene ble brukt i prosjektet:

- En baseling modell
- En enkel Feed Forward Neural Network (FFNN)
- En enkel Convolutional Neural Network (CNN)
- En forbedret CNN
- En CNN med data augmentation og regularisering
- En Transfer learning modell (MobileNetV2) med:
 - frozen base
 - fine-tuned

disse modellene viser en framskrift i prosjektet hvor modellene ble forbedret ut i fra omstendigheter som blant annet accuracy og confusion matrix.

Begrunnelse for valget av modell

En baseline modell ble laget for å gi et mål som skulle forbedres av mer avanserte modeller. modellen predikerte alle samples som adenocarcinoma da dette var den klassen som var størst i treningssettet og ville derfor gi høyest accuracy.

Etter baselinemodellen ble det laget en FFNN. Denne typen modell tar ikke hensyn til strukturen i bilder. Bildene blir representert som tall og flatet ut til en lang sekvens av tall og forventes derfor å prestere dårlig.

CNN-er ble deretter brukt, som i motsetning til FFNN er spesielt godt egnet for bildeanalyse. Ved bruk av konvolusjonslag kan modellen lage gode representasjoner av bilder og derfor lære komplekse mønstre i data.

Videre ble transfer learning brukt ved å benytte seg av en ferdig internt modell (MobileNetV2). Dette er spesielt nyttig fordi ferdigtrente modeller ikke er like avhengig av store mengder data som andre utrente modeller, som passer bra i dette tilfellet.

Modellstruktur

Alle modellene ble sammenlignet på slutten av prosjektet hvor den beste modellen ble valgt. Transfer Learning var den modellen med best resultat og ble derfor valgt. Modellen tar som input, bilder med størrelse 128x128 piksler og tre farger. Før bildene ble sendt inn i modellen ble det lagt til en enkel data argumentasjon som inneholdt tilfeldig zoom. Gjennom testing ble det gjort en oppdagelse om at argumentasjon med horizontal flip og rotasjon gjorde negativ hensikt på modellen. Bildets plassering er veldig viktig i medisinsk kontekst, og derfor ble bruken av data argumentasjon gjort med forsiktighet.

Kjernen i modellen består av MobileNetV2, en forhåndsdefinert konvolusjonsmodell trent på ImageNet datasettet. I denne versjonen er de forhåndsdefinerte vektene frosset, fordi dette viste seg å ha det beste resultatet. Det betyr at modellen ikke oppdaterer de interne vektene, men kun bruker de ferdigtrente representasjonene til å finne mønstre i bildene.

Etter MobileNetV2 sendes dataen videre til et globalt average pooling lag som skal redusere dimensjonen og fange opp de viktigste featurene. Deretter følger det et dens lag med ReLU aktiveringsfunksjon som lærer mer komplekse mønstre. for å redusere overfitting brukes dropout som deaktiverer tilfeldige neurons under trening.

Til slutt består modellen av et output lag med softmax aktiveringsfunksjon som regner ut sannsynligheten over de fire klassene: adenocarcinoma, large cell, squamous og normal.

(Legg til et flyt diagram / figur av modellen)

Hyperparametre

Flere hyperparametre påvirket modellenes ytelse:

- Learning rate (Adam optimizer)
- Batch size (32)
- Antall epoker (varierende ut ifra observasjoner)
- Dropout-rate (varierende)
- Antall filtre og lag i modellene
- Data augmentation parametre

Disse hyperparameterene ble ikke optimalisert med for eksempel grid search, men justert manuelt basert på observerte resultater (som validation loss og accuracy).

Treningsprosess

Alle modellene ble trent med:

```
loss = "sparse_categorical_crossentropy"
```

Dette passer bra til dette prosjektet hvor dataen inneholder flere klasser med heltallslabels.

Optimaliseringsalgoritmen som ble brukt er Adam. Denne ble valgt fordi den er robust og fungerer godt i de fleste deep learning problemer.

Alle modellene ble evaluert av samme metode, som inneholdt blant annet accuracy og confusion matrix. Evalueringen gjorde det mulig å undersøke om modellen overfittet, underfittet og hvordan man ellers kunne forbedre modellen videre.

For å redusere overfitting, ble følgende metoder brukt:

- Dropout
- Data argumentation
- Early stopping

Kode og repo

Koden for prosjektet er tilgjengelig i github-repo:

<https://github.com/chritof/Chest-Cancer-Detections-Using-Deep-Learning>

Repoet inneholder:

- Dataprossesering
- Utforskning og konklusjon om modeller
- Trening og validering
- Visualisering av resultatene, gjennom blant annet grafer og figurer
- App kode for Huggingface

Evaluering

Resultater

Den beste og mest stabile modellen i prosjektet fikk en accuracy på 68%. Dette tallet viser en tydelig forbedring med MobileNetV2 i forhold til baseline-modellen.

Med en accuracy på 68% så indikerer det at modellen kan klassifisere en stor andel av bildene riktig, men er også ikke gode nok til å bli brukt i praksis. Spesielt i det medisinske feltet hvor det er kritisk å være nøyaktig og presis. Dette gjør at modellen sitt resultat er et godt utgangspunkt, men kan ikke bli brukt uten videreutvikling.

Evaluering av modellens ytelse

For å analysere hvilke klasser modellen hadde utfordringer med, så brukte vi Confusion matrix. En Confusion matrix brukes for å evaluere ytelsen til en modell ved å gi en detaljert oversikt over “true positives”, “false positives”, “true negatives” og “false negatives”.

Resultatene viste at modellen hadde problemer med å gjenkjenne ulike krefttyper. Den forvekslet ulike krefttyper, siden bildene i datasettet var ganske like, samtidig som det var duplikater i de forskjellige klassene.

Under analyseringene så ble det observasjoner på de ulike klassene for å forstå recall og precision i modellen. Observasjonene viste at de enkelte klassene hadde lavere recall, som betyr at modellen ikke greide å gjenkjenne alle relevante tilfellene i klassene. Dette er en representasjon av “false negatives”, og er veldig dårlig når det kommer til medisin.

Det ble brukt F1-score for å balansere precision og recall, som er mer presis enn bare accuracy siden den ekskluderer “true negatives”.

Hvordan modellen er deployet

For å demonstrere bruken av modellen, ble den beste modellen som bestod av transfer learning med frossen MobileNetV2, lagt ut på en interaktiv nettside ved hjelp av Hugging Face Spaces.

Brukere kan gå inn på tjenesten og laste opp et bilde som vil bli prosessert på samme måte som under trening. Bildet sendes gjennom alle lagene i modellen, hvor modellen returnerer sannsynlighetsfordelingen over de fire klassene. Resultatet blir vist på nettsiden på en fin og brukervennlig måte.

Rammeverk

Prosjektet brukte TensorFlow/ Keras for modellutvikling og Gradio for å bygge brukergrensesnittet.

TensorFlow gidd en god og strukturert måte å jobbe på gjennom hele prosjektet, fra modelltrening til lagring og lasting av modeller.

Gradio ble valgt som frontend-løsning fordi det gir en enkel og grei måte å bygge nett-baserte applikasjoner på for maskinlæringsmodeller. Integrasjonen med Hugging Face gjør det også lett å publisere et grensesnitt på applikasjonen.

Monitorering og vedlikehold

For at modellen faktisk skal være nyttig over tid, krever det monitorering og vedlikehold.

Logging av brukerinput og modellpredikasjoner kan gjøres, slik at man kan analysere hvordan modellen presterer i praksis, og se om endringer i modellens oppførsel skjer over tid.

Endring av måten vi tar CT-bilder på kan være en viktig faktor, og må overvåkes. Modellen er trent på én type CT-bilder, men teknologi endres og måten vi tar CT-bilder på i dag, er kanskje endret om noen år. Dette gjør at jevnlig evaluering og eventuelt ny trening er nødvendig.

Videre forbedringer

Det vi kan se i dette kapittelet er at modellen må videreutvikles for å bli tatt i bruk. En av de tingene som kan forbedres er at modellen får et større og mer balansert datasett å jobbe med, sånn at modellen kan være mer nøyaktig og hindre overfitting. En mer avansert bruk av hyperparameteroptimalisering kan ha positiv effekt på modellens nøyaktighet. Det kan også diskuteres om alternativ modellarkitektur kan gi bedre svar. Brukeropplevelsen kan forbedres med å legge til et mer avansert brukergrensesnitt ved å for eksempel legge til forklaring av modellens predikasjoner.

Vurdering av prosjektet

Målet med prosjektet var å undersøke om deep learning kan brukes til å klassifisere medisinske bilder av lungene for å predikere forskjellige klasser av kreft. Flere modeller og forbedringer ble gjort gjennom prosjektet, fra enkel feed forward modell til mer avansert konvolusjonsmodeller og transfer learning.

	model	accuracy	precision_macro	recall_macro	f1_macro	f1_weighted
0	Transfer learning (frozen base) - validation	0.652778	0.728007	0.667566	0.668986	0.657306
1	Transfer learning (fine-tuned) - validation	0.597222	0.721079	0.626780	0.615237	0.596721
2	FFNN - validation	0.555556	0.567857	0.556331	0.548018	0.548846
3	Larger CNN - validation	0.527778	0.620073	0.544306	0.532646	0.509921
4	Improved CNN - validation	0.500000	0.453297	0.517391	0.451515	0.407744
5	CNN from scratch - validation	0.472222	0.408245	0.495652	0.434127	0.391138
6	FFNN + augmentation - validation	0.416667	0.339844	0.384615	0.307184	0.295291


Etter hver trente modell ble det logget like resultater av modellen, som accuracy, recall, loss og confusion matrix. På slutten ble alle modellene sammenlignet i en tabell ut ifra accuracy, precision, recall og f1-score. Resultatene viser at feedforward-modellen med data argumentasjon gjorde det desidert verst. Vi lærte at data augmentation kunne skade modellen. Predikasjon av medisinske bilder er avhengig av formen på bildet.

Et lignende mønster ble observert for konvolusjonsmodellene, hvor modellen med data augmentation gjorde det dårligere enn modellen uten. Det ble også observert at valg av seed hadde stor påvirkning på resultatene, hvor identiske modeller kunne variere med +/-10% i accuracy. Dette tyder på at datasettet er relativt lite og ubalansert, noe som gjør modellene mindre stabile. Dette støttes også av kommentarer fra andre brukere av datasettet på Kaggle.

Den beste modellen var ved bruk av transfer learning med en frossen MobileNetV2-base. Modellen oppnådde høyest accuracy med omtrent 65% accuracy og en macro f1 score på omtrent 0.67. Modellen klarte spesielt godt å predikere normale bilder, samtidig som ingen av klassene ble ignorert, i motsetning til enklere modeller hvor noen av klassene ble fullstendig ignorert. Dette viser at modellen klarer å finne gode mønstre i dataen.



Analyse av resultat

Selv om transfer learning modellen hadde best resultat, viser en nærmere analyse av confusion matrix at det fortsatt finnes utfordringer, spesielt når det gjelder å skille de ulike kreft typene.



Som vist i figuren kan vi se at modellen klarer i stor grad å skille mellom normale og unormale bilder, men har utfordringer med å skille mellom adenocarcinoma, large cell og squamous. Dette var som forventet, hvor forskjellen mellom disse klassene kan være vanskelig å fange opp, spesielt med begrenset datasett.

Videre viser trenings- og valideringskurvene at modellen klarer å fange mønstre i datasettet. Grafene viser også at validerings loss begynner å øke etter epoke 12, noe som kan tyde på litt overfitting.



Vurdering av metrikker

For å evaluere modellene gjennom prosjektet ble det brukt blant annet accuracy, precision, recall og f1-score.

I ettertid viste det seg at accuracy alene ikke var nok for å kunne måle suksess i modellene, spesielt på grunn av ubalanse i datasettet og vanskelighetene for å skille mellom de ulike klassene. Macro F1-score viste seg å være en mer informativ metrikk, siden den gir en mer balansert vurdering på tvers av klassene.

Bruken av confusion matrix viste seg å være et nyttig verktøy for å identifisere svakheter i modellen, spesielt for å se hvor godt modellen klarte å skille mellom de ulike klassene.

Samlet sett var disse metrikkene godt egnet for å kunne evaluere modellene.

Hva kunne vært annerledes?

I ettertid er det flere ting som kunne vært forbedret:

- Mer data: et større og mer balansert datasett hadde vært lettere å jobbe med og ville sannsynligvis gitt bedre resultater.
- Bedre håndtering av ubalanse i datasettet: for eksempel ved bruk av class weights eller fjerne samples fra dominerende klasser, men dette ville ført til et enda mindre datasett.
- Mer effektiv hyperparameteroptimalisering

Helhetlig vurdering

Prosjektet viser tydelig hvordan valg av modeller og metoder påvirker resultatet i deep learning. Gjennom analyse og sammenligning av modeller har det vært mulig å finne både styrker og svakheter som brukes for å videreutvikle modeller, og komme til en endelig modell.

Denne modellen gir et realistisk resultat, og viser potensialet til deep learning i en medisinsk kontekst. Resultatet av modellen viser også viktigheten av solide datasett, rett evalueringsteknikker, og kritisk refleksjon av modellenes predikasjoner og oppførsel.

Kilder

Husk å sitere alle kilder dere har brukt. Dere kan velge referansestil selv, men vær konsistent.

<https://www.who.int/news-room/fact-sheets/detail/cancer>

<https://sml.snl.no/kreft>

<https://huggingface.co/spaces>

<https://www.ibm.com/think/topics/confusion-matrix>

ChatGPT

Notater fra forelesningene og notebooks fra deep learning faget

*Textbook: F. Chollet: Deep Learning with Python, **3rd edition***